

# Penerapan Model Hibrida ARIMAX-Deep Neural Network untuk Peramalan *Inflow* dan *Outflow* Uang Kartal di Jawa Timur

Jemima Arista Putri dan Suhartono

Statistika, Fakultas Sains dan Analitika Data (FSAD), Institut Teknologi Sepuluh Nopember (ITS)

Jl. Arief Rahman Hakim, Surabaya 60111 Indonesia

e-mail: suhartono@statistika.its.ac.id

**Abstrak** - ARIMAX merupakan pengembangan model ARIMA dimana terdapat tambahan variabel eksogen sehingga dapat dilakukan regresi berganda, sedangkan Deep Neural Network (DNN) merupakan pengembangan dari NN dimana terdapat dua hidden layer yang diharapkan mampu mengenali proses lebih kompleks. Model ARIMAX memiliki kemampuan yang baik dalam menangkap pola linier dan DNN baik dalam menangkap pola non-linier dari data. Untuk meningkatkan akurasi peramalan, ARIMAX dikombinasikan secara series dengan DNN yakni dikenal dengan Hibrida ARIMAX-DNN. Penelitian ini bertujuan untuk mendapatkan model peramalan terbaik yang mengandung tren, musiman dan variasi kalender pada inflow dan outflow tiap KPw yang ada di Jawa Timur. Pemilihan metode terbaik yaitu berdasarkan nilai RMSE dan sMAPE terkecil diantara ARIMAX, DNN dan Hibrida ARIMAX-DNN. Hasil penelitian menunjukkan bahwa metode Hibrida ARIMAX-DNN merupakan metode terbaik yang terbanyak untuk meramalkan inflow dan outflow yaitu sebanyak 32 pecahan. Metode DNN baik untuk meramalkan 26 pecahan, sedangkan metode ARIMAX hanya baik digunakan untuk meramalkan 6 pecahan uang kertas. Sehingga dapat disimpulkan bahwa metode hibrida dan non-linier cenderung lebih baik untuk memodelkan inflow maupun outflow pecahan uang kertas yang ada di Jawa Timur.

**Kata Kunci** – ARIMAX, Deep Neural Network, Hibrida, Inflow, Jawa Timur, Outflow.

## I. PENDAHULUAN

Uang adalah suatu benda yang dapat ditukarkan dengan benda lain dan dapat disimpan. Uang dalam bentuk fisik, yaitu uang tunai yang berupa uang kertas dan uang logam yang beredar di masyarakat. Uang tunai adalah uang yang ada di tangan masyarakat (di luar bank umum) dan siap dibelanjakan setiap saat. Uang kartal merupakan suatu kebutuhan wajib bagi masyarakat, walaupun metode pembayaran online kian berkembang di Indonesia. Uang kartal juga merupakan alat pembayaran tunai yang sah untuk transaksi perekonomian di Indonesia. Uang kartal yang disetorkan oleh bank umum ke bank sentral disebut dengan *inflow*, sedangkan uang kartal yang keluar dari bank sentral ke bank umum melalui penarikan uang layak edar disebut dengan *outflow*. Bank sentral mendistribusikan uang kartal ke setiap Kantor Perwakilan (KPw). Setiap KPw memiliki persebaran uang kartal yang berbeda-beda. Jawa Timur memiliki empat KPw, yaitu KPw Surabaya, KPw Kediri, KPw Malang dan KPw Jember.

Pertumbuhan ekonomi Jawa Timur pada triwulan II 2018 mencapai 5,6% (yoy) dimana nilai ini lebih tinggi dibandingkan nasional yaitu sebesar 5,3% (yoy). Kinerja perekonomian Jawa Timur lebih baik dibandingkan DKI Jakarta, Jawa Barat dan Banten. Meningkatnya pertumbuhan ekonomi maka akan semakin banyak pula uang kartal yang beredar di masyarakat. Hal tersebut diperkuat dengan kondisi bahwa di Jawa Timur mengalami kondisi *net outflow*, kondisi ini terjadi ketika transaksi penarikan uang lebih besar

dari pada penyetoran uang. Jumlah *outflow* sebesar Rp36,56 triliun meningkat signifikan sebesar 99,39% dari triwulan I 2018 sejalan dengan momen Idul Fitri yang jatuh pada Juni 2018 [1]. Besarnya kenaikan pertumbuhan ekonomi di Jawa Timur yang mengakibatkan *net outflow* perlu mendapatkan perhatian lebih agar jumlah uang yang dicetak memiliki tingkat kesalahan yang rendah sehingga kerugian dapat diminimalisir, oleh karena itu dibutuhkan penelitian tentang pemodelan dan peramalan *inflow* dan *outflow* di Jawa Timur untuk mengatur aliran uang kartal yang masuk dan keluar.

Kebutuhan uang kartal setiap waktu berbeda secara signifikan. Hal ini disebabkan oleh beberapa faktor. Salah satu faktor yang mempengaruhi adalah variasi kalender hari besar atau hari libur seperti hari raya Idul Fitri. Suhartono, Lee dan Hamzah memperkenalkan suatu model regresi runtun waktu untuk pemodelan data yang mengandung pola variasi kalender [2]. Efek variasi kalender Idul Fitri diduga memberikan pengaruh yang berbeda terhadap data *inflow* dan *outflow*. Hal ini dikarenakan masyarakat cenderung menabung uang kembali setelah hari raya, sehingga nilai *inflow* juga akan dipengaruhi oleh bulan setelah Idul Fitri. Nilai *outflow* akan naik sebulan sebelum Idul Fitri dikarenakan masyarakat akan menarik uang sebelum Idul Fitri. Oleh karena itu penelitian ini akan menggunakan variabel prediktor yaitu variabel *dummy* bulan Idul Fitri dan satu bulan setelah Idul Fitri untuk data *inflow*, sedangkan untuk data *outflow* akan menggunakan variabel *dummy* bulan Idul Fitri dan satu bulan sebelum Idul Fitri.

Data *time series* khususnya data keuangan umumnya membentuk pola data non-linier. Pemodelan non-linier untuk peramalan seringkali menggunakan metode *Artifisial Neural Network* atau biasa disebut dengan *Neural Network*. Salah satu pengembangan *Neural Network* yaitu *Deep Learning* dimana memiliki lebih banyak layer dan diharapkan mampu mengenali proses lebih kompleks [3]. Penelitian *The M4 Competition: Results, findings, conclusion and way forward* menyatakan bahwa metode gabungan atau hibrida mampu menangkap pola data baik tren maupun *seasonal* dan secara rata-rata mampu meningkatkan nilai akurasi dibandingkan metode individual [4]. Hasil penelitian memberikan pernyataan yang sama, yaitu menggabungkan model linier dan non-linier adalah salah satu cara efektif untuk meningkatkan nilai akurasi [5].

Berdasarkan beberapa penelitian yang dilakukan menunjukkan bahwa tidak terdapat suatu metode peramalan yang selalu terbaik untuk meramalkan berbagai jenis data. Setiap metode memiliki kelebihan dan kekurangan masing-masing, sehingga perlu untuk membandingkan beberapa metode dalam melakukan peramalan [6]. Secara umum terdapat tiga pendekatan yang digunakan untuk meramalkan *inflow* dan *outflow* yaitu model peramalan linier, model

peramalan non-linier, dan model hibrida. Pada penelitian ini, model peramalan linier yang digunakan adalah model ARIMAX, untuk model non-linier yang digunakan adalah DNN serta model gabungan yang digunakan hibrida ARIMAX-DNN. Pemilihan model terbaik adalah berdasarkan nilai RMSE dan sMAPE terkecil. Penelitian ini diharapkan mampu membantu perencanaan pemenuhan kebutuhan uang kartal di Jawa Timur pada masa yang akan datang.

## II. TINJAUAN PUSTAKA

### A. Regresi Time Series

Salah satu model *time series* adalah regresi *time series* dimana secara umum model ini sama dengan model regresi linier[7]. Variabel prediktor yang digunakan adalah variabel dummy berupa tren, musiman dan variasi kalender Idul Fitri seperti persamaan berikut.

$$Y_t = \beta_1 t + \sum_{i=1}^S \alpha_i M_{i,t} + \sum_{j=1}^G \gamma_j V_{j,t} + \varepsilon_t, \quad (1)$$

dengan  $t$  merupakan *dummy* tren,  $M_{s,t}$  adalah *dummy* musiman,  $V_{G,t}$  adalah *dummy* variasi kalender Idul Fitri dan  $\varepsilon_t$  merupakan residual dari model regresi *time series* yang belum tentu memenuhi asumsi IIDN ( $0, \sigma_a^2$ ).

### B. Autoregressive Intergrated Moving Average with Exogeneous Variable (ARIMAX)

ARIMAX adalah pengembangan model ARIMA dimana terdapat tambahan variabel eksogen sehingga dapat dilakukan regresi berganda.  $\varepsilon_t$  merupakan residual regresi *time series* yang belum memenuhi asumsi *white noise*, dimana  $\varepsilon_t$  mengikuti persamaan ARIMA yakni  $\varepsilon_t = \frac{\theta_q(B)}{\phi_p(B)} a_t$ . Apabila


residual dari model regresi *time series* tidak memenuhi asumsi *white noise*, dilakukan pemodelan residual ( $\varepsilon_t$ ) menggunakan model ARIMA. Model umum ARIMAX yang mengandung pola tren, musiman, dan kalender variasi dinyatakan sebagai berikut [8].

$$Y_t = \beta_1 t + \sum_{i=1}^S \alpha_i M_{i,t} + \sum_{j=1}^G \gamma_j V_{j,t} + \frac{\theta_q(B)}{\phi_p(B)} a_t, \quad (2)$$

dimana  $\phi_p(B) = (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)$ ,  $a_t$  adalah residual model ARIMAX dan  $\theta_q(B) = (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q)$ .

### C. Deep Neural Netowrk (DNN)

*Deep Neural Network* (DNN) merupakan pengembangan dari *Neural Network* yang memiliki lebih banyak layer dan diharapkan mampu mengenali proses lebih kompleks. Arsitektur DNN dapat ditunjukkan pada Gambar 1.



Gambar 1. Arsitektur Deep Neural Network

*Input* yang akan digunakan pada penelitian ini adalah variabel *dummy* dan lag. Pemilihan lag *input* yaitu berdasarkan lag PACF yang signifikan pada data yang telah stasioner [9]. Pada *input* dan *hidden layer* memiliki bias yang bernilai satu [10]. Semakin banyak jumlah neuron yang digunakan pada *hidden layer* terdapat kemungkinan akan meningkatkan akurasi model, namun juga memungkinkan nilai prediksi *out-sample* menurun [11]. Oleh karena itu jumlah neuron yang digunakan pada *hidden layer* dicobakan dari satu hingga lima. Model umum yang digunakan pada DNN dapat digeneralisasi dari FFNN satu *layer* dan dapat ditunjukkan sebagai berikut [12].

$$\hat{Y}_{(t)} = f^o \left[ b^o + \sum_{i=1}^p w_i^o f_i^{h_2} \left( b_i^{h_2} + \sum_{j=1}^q w_{ji}^{h_2} f_j^{h_1} \left( b_j^{h_1} + \sum_{k=1}^r w_{kj}^{h_1} X_{k(t)} \right) \right) \right] \quad (3)$$

dengan  $X_{k(t)}$  adalah variabel *input*,  $\hat{Y}_{(t)}$  adalah nilai dugaan variabel *output*,  $f^o$  adalah fungsi aktivasi pada neuron di lapisan output.  $b^o$  adalah bias pada neuron,  $w_i^o$  adalah bobot neuron menuju *output layer*,  $w_{ji}^{h_2}$  adalah bobot neuron menuju *hidden layer 2*,  $w_{kj}^{h_1}$  adalah bobot neuron menuju *hidden layer 1*.

1. Algoritma yang paling sering digunakan analisis *time series* yaitu dengan melakukan *fitting* terhadap parameter-parameter fungsi khususnya untuk mengubah bobot-bobot yang terhubung dengan neuron-neuron pada *hidden layer* adalah algoritma *backpropagation* dengan metode *gradient descent* [13]. Fungsi aktivasi yang digunakan pada *hidden layer* adalah fungsi sigmoid. Fungsi ini baik digunakan dalam neural network yang menggunakan *backpropagation* karena dapat meminimalkan perhitungan [14]. Fungsi aktivasi yang paling banyak digunakan untuk *output layer* adalah fungsi linier karena fungsi aktivasi non-linier dapat menyebabkan distorsi pada *output* yang ditentukan [15].

### D. Hibrida ARIMAX-DNN

Penggabungan model *time series* memiliki nilai akurasi peramalan yang lebih baik dibandingkan model individual. Berdasarkan penelitian *M4-Competition* menunjukkan bahwa metode gabungan secara rata-rata mampu meningkatkan akurasi peramalan dibanding model individual [4]. Model ARIMAX mampu menangkap pola linier, namun tidak mampu menangkap pola non-linier. Oleh karena itu penelitian ini menggabungkan metode ARIMAX dan *Deep Neural Network* secara *series* dengan harapan mampu menangkap pola linier dan non-linier. Hibrida *series* terdiri dari komponen linier dan non-linier dimana komponen ini diproses secara berurutan.. Model umum dari hibrida *time series* adalah sebagai berikut [5].

$$Y_t = Y_t^{(l)} + Y_t^{(n)} + e_t \quad (4)$$

dengan  $Y_t^{(l)}$  adalah komponen linier dan  $Y_t^{(n)}$  adalah komponen non-linier.

### E. Evaluasi Model

Penelitian ini menggunakan 3 model yaitu ARIMAX, *Deep Neural Network* dan hibrida ARIMAX *Deep Neural Network*. Model yang tepat untuk *in-sample* belum tentu menghasilkan nilai kebaikan model yang tinggi pada data *out-sample* [6]. Oleh karena itu pada penelitian ini memilih model terbaik berdasarkan data *out-sample*. Seringkali RMSE lebih dipilih dibandingkan MSE jika data yang digunakan memiliki

skala yang sama. Umumnya RMSE sangat sering digunakan karena relevan dengan pemodelan statistik [16]. Persamaan RMSE ditunjukkan sebagai berikut.

$$RMSE = \sqrt{\frac{1}{L} \sum_{l=1}^L (Y_{n+l} - \hat{Y}_n(l))^2} \quad (5)$$

Akan tetapi, RMSE sangat sensitif jika terdapat data *outlier*. Sehingga digunakan ukuran kebaikan model lainnya yaitu sMAPE dikarenakan sMAPE lebih stabil jika terdapat data *outlier* [17]. Penggunaan ukuran kebaikan model sMAPE juga menghindari nilai *error* yang besar ketika terdapat data aktual yang mendekati 0 [18]. Persamaan sMAPE ditunjukkan sebagai berikut.

$$sMAPE = \left( \frac{1}{L} \sum_{l=1}^L \frac{2|Y_{n+l} - \hat{Y}_n(l)|}{(|Y_{n+l}| + |\hat{Y}_n(l)|)} \right) \times 100\% \quad (6)$$

#### F. Uang Kartal

Uang adalah suatu benda yang dapat ditukarkan dengan benda lain dan dapat disimpan. Uang tunai adalah uang yang ada di tangan masyarakat dan siap dibelanjakan terutama untuk pembayaran-pembayaran dalam jumlah yang tidak terlalu besar. Uang tunai tersebut sering disebut sebagai uang kartal yang terdiri dari uang kertas dan uang logam. Dengan uang kartal masyarakat dapat melakukan pembayaran tunai secara langsung [19].

Transaksi penarikan uang rupiah (*outflow*) merupakan informasi mengenai aliran uang kertas dan uang logam yang keluar dari bank sentral kepada perbankan dan masyarakat, sedangkan transaksi penyeteroran uang rupiah (*inflow*) merupakan informasi mengenai aliran uang kertas dan uang logam yang masuk dari perbankan dan masyarakat ke bank sentral [20].

### III. METODOLOGI PENELITIAN

#### A. Sumber Data

Data yang digunakan dalam penelitian ini adalah data sekunder yang merupakan data *inflow* dan *outflow* uang kartal Bank “X” di Jawa Timur dengan periode bulanan mulai bulan Januari 2010 hingga Juni 2019. Data akan dibagi menjadi data *in-sample* dan *out-sample*. Data *in-sample* yang digunakan yaitu data Januari 2010 hingga Desember 2017, sedangkan data *out-sample* yaitu data Januari 2018 hingga Juni 2019.

#### B. Variabel Penelitian

Variabel penelitian yang digunakan pada penelitian ini terdiri dari 8 pecahan uang kertas pada *inflow* dan *outflow*. Berikut merupakan variabel yang akan digunakan dalam penelitian ini.

**Tabel 1.** Variabel Penelitian

Variabel	Inflow	Variabel	Outflow
$Y_{1,t}^{(i)}$	Total	$Y_{9,t}^{(i)}$	Total
$Y_{2,t}^{(i)}$	Rp100.000,00	$Y_{10,t}^{(i)}$	Rp100.000,00
$Y_{3,t}^{(i)}$	Rp50.000,00	$Y_{11,t}^{(i)}$	Rp50.000,00
$Y_{4,t}^{(i)}$	Rp20.000,00	$Y_{12,t}^{(i)}$	Rp20.000,00
$Y_{5,t}^{(i)}$	Rp10.000,00	$Y_{13,t}^{(i)}$	Rp10.000,00
$Y_{6,t}^{(i)}$	Rp5.000,00	$Y_{14,t}^{(i)}$	Rp5.000,00
$Y_{7,t}^{(i)}$	Rp2.000,00	$Y_{15,t}^{(i)}$	Rp2.000,00
$Y_{8,t}^{(i)}$	Rp1.000,00	$Y_{16,t}^{(i)}$	Rp1.000,00

Tabel 1 menunjukkan variabel *inflow* dan *outflow* untuk KPw<sub>i</sub> dengan  $i=1,2,3,4$  dimana KPw<sub>1</sub> adalah Jember, KPw<sub>2</sub> adalah Kediri, KPw<sub>3</sub> adalah Malang dan KPw<sub>4</sub> adalah Surabaya. Sedangkan untuk variabel *dummy* dapat ditunjukkan pada Tabel 2.

**Tabel 2.** Variabel Dummy

Dummy	Keterangan
Tren	$t = 1, 2, 3, \dots, n$
Musiman	$M_{i,t} = \begin{cases} 1 & \text{untuk bulan ke } i, i=1, 2, \dots, 12 \\ 0 & \text{lainnya} \end{cases}$
Variasi Kalender (Idul Fitri)	$V_{j,t-1} = \begin{cases} 1 & \text{untuk minggu ke } j \text{ satu bulan sebelum Idul Fitri} \\ 0 & \text{lainnya} \end{cases}$ $V_{j,t} = \begin{cases} 1 & \text{untuk minggu ke } j \text{ ketika bulan Idul Fitri} \\ 0 & \text{lainnya} \end{cases}$ $V_{j,t+1} = \begin{cases} 1 & \text{untuk minggu ke } j \text{ satu bulan setelah Idul Fitri} \\ 0 & \text{lainnya} \end{cases}$

Pola variasi kalender pada data mengikuti terjadinya Idul Fitri dengan ketentuan minggu ke-1 adalah tanggal 1 sampai 7, minggu ke-2 adalah tanggal 8 sampai 15, minggu ke-3 adalah tanggal 16 sampai 23 dan minggu ke-4 adalah tanggal 24 sampai akhir. Data terjadinya Idul Fitri dari tahun 2010 hingga 2020 disajikan pada Tabel 3.

**Tabel 3.** Daftar Idul Fitri Tahun 2010-2020

Tahun	Tanggal Idul Fitri	Minggu ke- $j$	Variabel Dummy		
			$V_{j,t-1}$	$V_{j,t}$	$V_{j,t+1}$
2010	10-11 Sept	2	Agust	Sept	Okt
2011	30-31 Agus	4	Juli	Agust	Sept
2012	19-20 Agus	3	Juli	Agust	Sept
2013	08-09 Agus	2	Juli	Agust	Sept
2014	28-29 Juli	4	Juni	Juli	Agust
2015	17-18 Juli	3	Juni	Juli	Agust
2016	06-07 Juli	1	Juni	Juli	Agust
2017	26-27 Juni	4	Mei	Juni	Juli
2018	15-16 Juni	3	Mei	Juni	Juli
2019	3-4 Juni	1	Mei	Juni	Juli
2020	23-24 Mei	4	April	Mei	Juni

#### C. Langkah Analisis

Penelitian ini dilakukan beberapa tahapan untuk meramalkan *inflow* dan *outflow* di Jawa Timur yaitu sebagai berikut.

1. Mendekripsikan karakteristik data pada *inflow* maupun *outflow* untuk setiap KPw di Provinsi Jawa Timur melalui statistika deskriptif maupun secara visual dengan diagram.
2. Membagi data menjadi dua, yaitu data *in-sample* dan data *out-sample*. Data *in-sample* yaitu mulai Januari 2010 hingga Desember 2017, sedangkan data *out-sample* yaitu mulai Januari 2018 hingga Juni 2019.
3. Melakukan pemodelan dan peramalan untuk semua pecahan uang kertas dan total *inflow* maupun *outflow* di setiap KPw menggunakan metode ARIMAX dengan langkah sebagai berikut.
  - a. Meregresikan variabel respon dengan variabel *dummy* yang digunakan.

- i. Meregresikan *inflow* dengan variabel *dummy* tren, musiman, variasi kalender bulan Idul Fitri dan satu bulan setelah Idul Fitri. Hasil dari pemodelan regresi *time series* ini membentuk persamaan untuk data *inflow*.

$$Y_t = \beta_1 t + \sum_{i=1}^{12} \alpha_i M_{i,t} + \sum_{j=1}^4 \gamma_j V_{j,t} + \sum_{j=1}^4 \omega_j V_{j,t+1} + \varepsilon_t. \quad (7)$$

- ii. Meregresikan *outflow* dengan variabel *dummy* tren, musiman, variasi kalender bulan Idul Fitri dan satu bulan sebelum Idul Fitri. Hasil dari pemodelan regresi *time series* ini membentuk persamaan untuk data *outflow*.

$$Y_t = \beta_1 t + \sum_{i=1}^{12} \alpha_i M_{i,t} + \sum_{j=1}^4 \gamma_j V_{j,t} + \sum_{j=1}^4 \omega_j V_{j,t-1} + \varepsilon_t. \quad (8)$$

- c. Melakukan cek diagnosa pada residual regresi *time series*, jika memenuhi asumsi *white noise* maka dilanjutkan dengan peramalan menggunakan model regresi *time series*. Namun jika belum memenuhi asumsi maka dilanjutkan ke langkah selanjutnya.
  - d. Melakukan pemodelan ARIMA dengan identifikasi melalui orde ACF dan PACF pada residual regresi *time series*.
  - e. Melakukan cek diagnosa kembali pada residual model ARIMAX.
  - f. Melakukan peramalan dengan model ARIMAX dan mendapatkan nilai RMSE maupun sMAPE.
4. Melakukan pemodelan dan peramalan data *inflow* dan *outflow* untuk setiap pecahan menggunakan metode *Deep Neural Network* dengan langkah sebagai berikut:
- a. Menentukan variabel *input* berdasarkan variabel komponen tren, musiman dan kalender variasi pada ARIMAX serta lag variabel respon berdasarkan plot PACF yang signifikan.
  - b. Melakukan *preprocessing* data yaitu lag PACF yang signifikan menggunakan normalisasi. *Preprocessing* perlu dilakukan dan data akan bernilai antara 0 sampai 1 [12].

$$Y_t^* = \frac{Y_t - \min(Y_t)}{\max(Y_t) - \min(Y_t)}. \quad (9)$$

- c. Menentukan banyak *input*, jumlah neuron dalam *hidden layer* dan fungsi aktivasi.
  - d. Melakukan peramalan dengan arsitektur *Deep Neural Network* dan mendapatkan nilai RMSE maupun sMAPE.
  - e. Melakukan *postprocessing* data.
- $$Y_t = Y_t^* (\max(Y_t) - \min(Y_t)) + \min(Y_t). \quad (10)$$
5. Melakukan pemodelan dan peramalan data *inflow* dan *outflow* untuk setiap pecahan menggunakan metode hibrida *series* dengan langkah sebagai berikut.
  - a. Melakukan pemodelan ARIMAX pada data *inflow* maupun *outflow*.
  - b. Melakukan normalisasi pada lag pada residual yang

akan digunakan sebagai *input* pemodelan DNN.

- c. Menggunakan dua jenis input lag, input lag yang pertama adalah menggunakan orde AR pada model ARIMAX dan input lag yang kedua adalah lag1,12,35 sebagai justifikasi tren, musiman dan variasi kalender.
  - d. Menggabungkan model ARIMAX dan DNN menjadi model hibrida ARIMAX-DNN.
  - e. Melakukan *postprocessing* data.
6. Membandingkan model ARIMAX, *Deep Neural Network* dan hibrida *series* ARIMAX-DNN dan memilih model terbaik berdasarkan nilai RMSE dan sMAPE pada data *out-sample*.
7. Mendapatkan hasil peramalan untuk semua pecahan di setiap KPw Provinsi Jawa Timur.

#### IV. HASIL DAN PEMBAHASAN


##### A. Karakteristik Inflow dan Outflow di Provinsi Jawa Timur


Analisis deskriptif dilakukan untuk mengetahui gambaran umum data *inflow* dan *outflow* pada bulan Januari 2010 hingga Juni 2019 di 4 KPw yang tersebar di Provinsi Jawa Timur yaitu KPw Jember, KPw Kediri, KPw Malang dan KPw Surabaya.

Tabel 4. Statistika Deskriptif Total Pecahan Uang Kertas

KPw	Data	Mean	StDev	Min	Max
Jember	<i>Inflow</i>	855	530	172	3.059
	<i>Outflow</i>	665	572	5.2	3.352
Kediri	<i>Inflow</i>	999	700	159	3.622
	<i>Outflow</i>	1.153	935	38	5.745
Malang	<i>Inflow</i>	1.143	564	267	3.327
	<i>Outflow</i>	701	661	5.9	3.753
Surabaya	<i>Inflow</i>	2.740	1.806	463	10.609
	<i>Outflow</i>	2.658	2.032	322	11.756

Berdasarkan Tabel 4 diketahui jika rata-rata *inflow* tertinggi adalah di KPw Surabaya sebesar 2.740 miliar rupiah dengan nilai standar deviasi 1.806, lalu diikuti oleh KPw Malang sebesar 1.143 miliar rupiah dengan standar deviasi 564, KPw Kediri 999 miliar rupiah dengan standar deviasi 700 dan rata-rata *inflow* terendah yaitu di KPw Jember sebesar 855 miliar rupiah dengan standar deviasi 530. Sama halnya dengan rata-rata *inflow*, rata-rata *outflow* yang tertinggi adalah KPw Surabaya sebesar 2.658 miliar rupiah dan yang terendah juga KPw Jember yaitu sebesar 665 miliar rupiah. Sedangkan untuk KPw Kediri memiliki rata-rata sebesar 1.153 miliar rupiah dimana nilai ini lebih unggul dibandingkan KPw Malang yaitu sebesar 701 miliar rupiah dengan standar deviasi sebesar 661. Karakteristik *inflow* dan *outflow* pada tiap KPw dijelaskan lebih lanjut sebagai berikut.

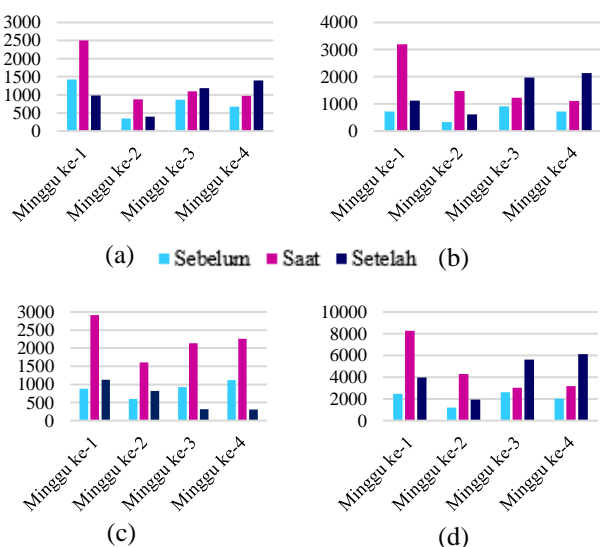




**Gambar 2.** Rata-Rata *Inflow* dan *Outflow* Total Uang Kertas dalam Bulan di (a) KPw Jember, (b) KPw Kediri, (c) KPw Malang dan (d) KPw Surabaya

Berdasarkan Gambar 2 dapat diketahui jika *inflow* total uang kertas tertinggi di keempat KPw yang ada di Provinsi Jawa Timur terjadi pada bulan Januari, Juni, Juli dan Agustus. Hal ini diduga karena pada bulan Desember masyarakat merayakan tahun baru dan natal, sehingga pada bulan Januari cenderung menyetorkan uangnya ke Bank. Sedangkan pada bulan Juni, Juli dan Agustus merupakan bulan yang berkaitan dengan terjadinya Idul Fitri. Rata-rata *outflow* total uang kertas tertinggi baik di KPw Jember, KPw Kediri, KPw Malang dan KPw Surabaya yaitu pada bulan Mei, Juni, Juli dan Desember. Sama halnya dengan rata-rata *inflow*, bulan Mei, Juni dan Juli merupakan bulan yang berkaitan dengan Idul Fitri. Pada bulan Desember, masyarakat cenderung mengambil uangnya di Bank sebelum merayakan natal atau tahun baru.

Diagram batang pada Gambar 3 menunjukkan adanya pengaruh yang signifikan Idul Fitri terhadap pergerakan *inflow* maupun *outflow* total uang kertas di tiap KPw yang ada di Provinsi Jawa Timur. Pada penelitian sebelumnya juga menunjukkan adanya pengaruh Idul Fitri berkaitan dengan minggu terjadinya Idul Fitri. Rata-rata *inflow* pada saat dan satu bulan setelah Idul Fitri ditunjukkan pada Gambar 3.



**Gambar 3.** Rata-Rata *Inflow* Total Uang Kertas Menurut Minggu Idul Fitri di (a) KPw Jember, (b) KPw Kediri, (c) KPw Malang dan (d) KPw Surabaya

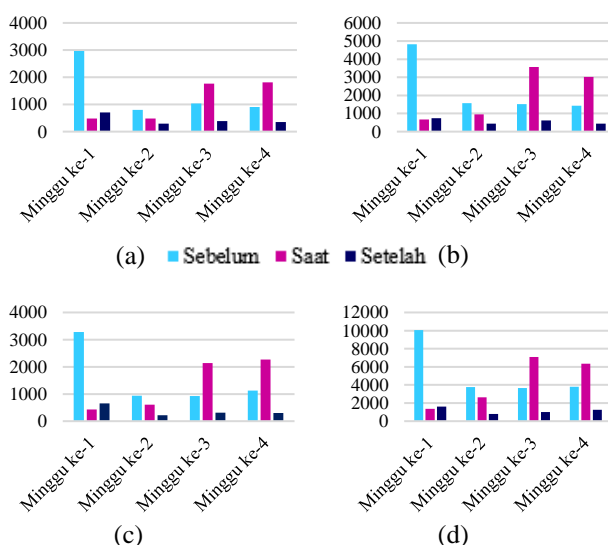
Gambar 3 menunjukkan rata-rata kenaikan *inflow* total pecahan kertas di keempat KPw yang ada di Provinsi Jawa Timur pada periode Januari 2010 hingga Juni 2019. Kenaikan *inflow* berdasarkan minggu Idul Fitri memiliki pola sebagai berikut.

1. Apabila Idul Fitri terjadi pada minggu pertama, maka rata-rata *inflow* memiliki nilai yang sangat tinggi pada

bulan terjadinya Idul Fitri dan menurun pada satu bulan setelah Idul Fitri.

2. Apabila Idul Fitri terjadi pada minggu kedua, maka rata-rata *inflow* memiliki nilai yang lebih tinggi dibandingkan satu bulan setelah Idul Fitri
3. Apabila Idul Fitri terjadi pada minggu ketiga, maka rata-rata *inflow* memiliki nilai yang hampir sama dengan satu bulan setelah Idul Fitri.
4. Apabila Idul Fitri terjadi pada minggu keempat, maka rata-rata *inflow* akan tinggi pada satu bulan setelah terjadinya Idul Fitri.

Pola kenaikan *outflow* memiliki perbedaan dengan pola kenaikan *inflow*. *Outflow* dipengaruhi oleh bulan terjadinya Idul Fitri dan satu bulan sebelum terjadinya Idul Fitri karena masyarakat cenderung menarik uang sebelum merayakan Idul Fitri. Untuk lebih jelasnya ditunjukkan pada Gambar 4.



**Gambar 4.** Rata-Rata *Outflow* Total Uang Kertas Menurut Minggu Idul Fitri di (a) KPw Jember, (b) KPw Kediri, (c) KPw Malang dan (d) KPw Surabaya

Berdasarkan Gambar 4 diketahui rata-rata kenaikan *outflow* total pecahan kertas di keempat KPw yang ada di Provinsi Jawa Timur pada periode Januari 2010 hingga Juni 2019. Kenaikan *outflow* berdasarkan minggu Idul Fitri memiliki pola sebagai berikut.

1. Apabila Idul Fitri terjadi pada minggu pertama, maka rata-rata *outflow* memiliki nilai yang sangat rendah pada bulan terjadinya Idul Fitri dan pada satu bulan sebelum terjadinya Idul Fitri memiliki nilai yang sangat tinggi.
2. Apabila Idul Fitri terjadi pada minggu kedua, maka rata-rata *outflow* memiliki nilai yang hampir sama dengan satu bulan sebelum Idul Fitri.
3. Apabila Idul Fitri terjadi pada minggu ketiga, maka rata-rata *outflow* memiliki nilai yang lebih tinggi dibandingkan satu bulan sebelum Idul Fitri.
4. Apabila Idul Fitri terjadi pada minggu keempat, maka rata-rata *outflow* akan tinggi pada saat terjadinya Idul Fitri.




### B. Pemodelan Inflow dan Outflow dengan ARIMAX di Provinsi Jawa Timur

Langkah yang dilakukan sebelum melakukan pemodelan data *inflow* dan *outflow* dengan ARIMAX adalah memodelkan dengan regresi *time series*. Dilakukan regresi *time series* pada data *inflow* Rp50.000 di KPw Jember dengan variabel prediktor yaitu variabel *dummy* yang terdiri dari *dummy* tren, *dummy* bulan dan *dummy* variasi kalender. Setelah dilakukan regresi *time series*, didapatkan hasil estimasi parameter dan dilakukan uji Ljung Box untuk cek *white noise*.

**Tabel 4.** Uji Asumsi Residual Regresi *Time Series*

Hingga Lag ke-	Chi-Square	DF	P-Value
6	13,23	6	0,0395
12	17,13	12	0,1447
18	21,73	18	0,2440
24	27,33	24	0,2893
30	37,54	30	0,1620
36	43,32	36	0,1873

Berdasarkan Tabel 4 dapat diketahui jika terdapat *p-value* dari uji Ljung Box yang kurang dari 0,05. Hal ini menunjukkan jika residual *inflow* uang kertas pecahan Rp50.000,00 di KPw Jember belum memenuhi asumsi *white noise* yang berarti residual independen atau mengandung autokorelasi. Selanjutnya dilakukan pemodelan menggunakan ARIMA berdasarkan plot ACF dan PACF pada residual hasil pemodelan menggunakan regresi *time series* guna memenuhi asumsi independen. Plot ACF dan PACF dari residual *inflow* uang kertas pecahan Rp50.000,00 di KPw Jember ditunjukkan pada Gambar 5.



**Gambar 4.** ACF dan PACF Residual Regresi *Time Series*

Berdasarkan plot ACF dan PACF pada Gambar 4.9 maka didapatkan dugaan model ARIMA dari residual *inflow* uang kertas pecahan Rp50.000 di KPw Jember. Hasil dugaan model selanjutnya dilakukan estimasi parameter dan uji asumsi residual. Persamaan model ARIMAX yang didapatkan untuk *inflow* uang kertas pecahan Rp50.000,00 di KPw Jember adalah sebagai berikut.

$$\begin{aligned}
 Y_t = & 4,1101t + 204,502M_{1,t} + 96,6047M_{2,t} + 50,658M_{3,t} \\
 & + 36,8312M_{4,t} + 93,4497M_{5,t} + 70,6233M_{6,t} + 80,4717M_{7,t} \\
 & + 53,5539M_{8,t} + 33,5816M_{9,t} + 44,0327M_{10,t} + 61,8094M_{11,t} \\
 & + 33,9793M_{12,t} + 248,450V_{1,t} - 2,44008V_{1,t+1} + 201,814V_{2,t} \\
 & + 12,0212V_{2,t+1} + 142,363V_{3,t} - 1,51067V_{3,t+1} - 76,1263V_{4,t} \\
 & + 290,622V_{4,t+1} + \frac{1}{(1-0,37929B)}a_t.
 \end{aligned}$$


Didapatkan model *inflow* uang kertas pecahan Rp50.000,00 di KPw Jember yaitu ARIMA(1,0,0) dan residual telah memenuhi asumsi *white noise* dan berdistribusi normal. Dilakukan hal yang sama untuk pecahan uang kertas lainnya untuk KPw Jember dan KPw lainnya.

**Tabel 4.** Pemodelan ARIMAX *Inflow* dan *Outflow* di Jawa Timur

Variabel	Model	Residual	
		White Noise	Distribusi Normal
Inflow di KPw Jember	Total	Regresi <i>Time Series</i>	Ya
	100.000	Regresi <i>Time Series</i>	Ya
	50.000	ARIMAX(1,0,0)	Ya
	20.000	ARIMAX([1,11],0,0)	Tidak
	10.000	Regresi <i>Time Series</i>	Tidak
	5.000	ARIMAX([1,11,12],0,0)	Tidak
	2.000	ARIMAX([1,10],0,0)	Tidak
	1.000	ARIMAX(0,0,[1,2,8,9])	Ya
Outflow di KPw Jember	Total	ARIMAX([3],0,0)	Ya
	100.000	ARIMAX([3],0,0)	Tidak
	50.000	ARIMAX([3,10,12],0,0)	Tidak
	20.000	ARIMAX(0,0,1)	Ya
	10.000	ARIMAX(0,0,1)	Ya
	5.000	ARIMAX(0,0,1)	Ya
	2.000	ARIMAX(0,0,1)	Ya
	1.000	Regresi <i>Time Series</i>	Tidak
Inflow di KPw Kediri	Total	Regresi <i>Time Series</i>	Ya
	100.000	Regresi <i>Time Series</i>	Ya
	50.000	Regresi <i>Time Series</i>	Tidak
	20.000	Regresi <i>Time Series</i>	Tidak
	10.000	Regresi <i>Time Series</i>	Tidak
	5.000	ARIMAX([1,11],0,0)	Ya
	2.000	ARIMAX([1,2,12],0,0)	Ya
	1.000	ARIMAX(1,0,0)	Ya
Outflow di KPw Kediri	Total	Regresi <i>Time Series</i>	Ya
	100.000	Regresi <i>Time Series</i>	Ya
	50.000	ARIMAX([17,22],0,0)	Tidak
	20.000	Regresi <i>Time Series</i>	Tidak
	10.000	ARIMAX([1,11],0,0)	Tidak
	5.000	Regresi <i>Time Series</i>	Tidak
	2.000	Regresi <i>Time Series</i>	Tidak
	1.000	ARIMAX(0,0,[12])	Tidak
Inflow di KPw Malang	Total	ARIMAX(2,0,0)	Ya
	100.000	ARIMAX([1,2,4],0,0)	Ya
	50.000	ARIMAX([1,2,12],1,0)	Ya
	20.000	Regresi <i>Time Series</i>	Tidak
	10.000	Regresi <i>Time Series</i>	Tidak
	5.000	Regresi <i>Time Series</i>	Tidak
	2.000	ARIMAX(1,0,0)	Ya
	1.000	ARIMAX(1,0,0)	Tidak
Outflow di KPw Malang	Total	ARIMAX(2,0,0)	Ya
	100.000	ARIMAX(2,0,0)	Ya
	50.000	Regresi <i>Time Series</i>	Tidak
	20.000	ARIMAX([1,11,12],0,0)	Ya
	10.000	ARIMAX([1,11],0,0)	Tidak
	5.000	Regresi <i>Time Series</i>	Tidak
	2.000	Regresi <i>Time Series</i>	Tidak
	1.000	Regresi <i>Time Series</i>	Tidak
Inflow di KPw Surabaya	Total	ARIMAX([2,4],0,0)	Ya
	100.000	ARIMAX([4],0,0)	Tidak
	50.000	ARIMAX(3,1,0)	Ya
	20.000	ARIMAX(1,0,0)	Tidak
	10.000	ARIMAX([1,11],0,0)	Tidak
	5.000	ARIMAX([1,2,11],0,0)	Tidak
	2.000	ARIMAX([1,4],0,0)	Ya
	1.000	ARIMAX(0,0,[1,2,10])	Tidak
Outflow di KPw Surabaya	Total	ARIMAX([3],0,0)	Ya
	100.000	ARIMAX([3],0,0)	Ya
	50.000	ARIMAX([3],0,0)	Ya
	20.000	Regresi <i>Time Series</i>	Tidak
	10.000	Regresi <i>Time Series</i>	Tidak
	5.000	ARIMAX(0,0,1)	Tidak
	2.000	ARIMAX([1,23],0,0)	Tidak
	1.000	Regresi <i>Time Series</i>	Tidak

### C. Pemodelan Inflow dan Outflow dengan Deep Neural Network di Provinsi Jawa Timur

Langkah yang dilakukan untuk memodelkan *inflow* dan *outflow* dengan *Deep Neural Network* (DNN). *Input* pada DNN adalah lag PACF yang signifikan, *dummy* tren, *dummy* bulan dan *dummy* variasi kalender. Arsitektur yang digunakan adalah dua *hidden layer* dengan jumlah masing-masing *layer* adalah satu hingga lima neuron. Fungsi aktivasi yang digunakan pada *hidden layer* adalah sigmoid dan fungsi aktivasi yang digunakan pada *output layer* adalah linier. Sedangkan untuk nilai pembobot didapatkan menggunakan algoritma *backpropagation* dengan melakukan replikasi sebanyak 10 kali guna mendapatkan nilai pembobot terbaik. *Input* yang digunakan adalah lag signifikan dari PACF data yang telah stasioner. *Inflow* uang kertas pecahan Rp50.000,00 di KPw Jember belum stasioner sehingga dilakukan *differencing seasonal* dan *non-seasonal*. Berikut adalah plot PACF data yang telah stasioner.




Gambar 5. PACF Inflow Pecahan Rp50.000 Stasioner

Gambar 5 menunjukkan jika terdapat 1 lag yang signifikan yaitu lag 1. Karena data telah dilakukan *differencing*, maka penjabaran model yaitu sebagai berikut.

$$a_t = (1-B)(1-B^{12})(1-\phi_1 B) \dot{Y}_t$$


$$\dot{Y}_t = (1+\phi_1)\dot{Y}_{t-1} - \phi_1 \dot{Y}_{t-2} + \dot{Y}_{t-12} - (1+\phi_1)\dot{Y}_{t-13} + \phi_1 \dot{Y}_{t-14} + a_t$$

Setelah dilakukan penjabaran model, didapatkan *input* yang digunakan adalah lag 1, 2, 12, 13, 14 dan variabel *dummy*. Selanjutnya dilakukan uji Terasvirta terhadap lag *input* dengan data dan didapatkan hasil bahwa model non-linier adalah model yang sesuai untuk menjelaskan hubungan  $Y_t$  dengan *input*nya. Pemilihan arsitektur terbaik adalah berdasarkan nilai RMSE dan sMAPE terkecil pada data *out-sample* yang ditunjukkan pada Gambar 6.



Gambar 6. RMSE dan sMAPE DNN untuk Semua Kombinasi

Neuron yang digunakan adalah 1 sampai 5 pada *hidden layer* 1 dan *hidden layer* 2 sehingga terdapat 25 kombinasi. Dari 25 kombinasi dapat diketahui jika nilai RMSE dan sMAPE terkecil data *out-sample* yaitu pada kombinasi ke-23. Berikut adalah hasil arsitektur optimum pada kombinasi ke-23 data *inflow* Rp50.000 di KPw Jember.



Gambar 7. Arsitektur Optimum DNN

Gambar 7 menunjukkan jika arsitektur optimum pada *inflow* pecahan Rp50.000 di KPw Jember. Dilakukan cara yang sama untuk pecahan uang lainnya.

Tabel 4. Pemodelan DNN *Inflow* dan *Outflow* di Jawa Timur

Variabel	Lag Input	Neuron di Hidden Layer	
		1	2
Inflow di KPw Jember	Total	2	4
	100.000	4	3
	50.000	3	5
	20.000	3	5
	10.000	3	2
	5.000	3	5
	2.000	3	2
Outflow di KPw Jember	1.000	4	1
	Total	5	2
	100.000	5	2
	50.000	1	1
	20.000	3	2
	10.000	4	5
	5.000	2	4
Inflow di KPw Kediri	2.000	4	4
	1.000	2	2
	Total	1	4
	100.000	2	4
	50.000	1	4
	20.000	5	1
	10.000	5	2
Outflow di KPw Kediri	5.000	4	3
	2.000	3	4
	1.000	1	5
	Total	5	5
	100.000	5	5
	50.000	3	2
	20.000	3	1
Inflow di KPw Malang	10.000	1	3
	5.000	2	2
	2.000	3	4
	1.000	5	4
	Total	1	3
	100.000	1	2
	50.000	4	2
Outflow di KPw Malang	20.000	1	1
	10.000	1	1
	5.000	1	2
	2.000	5	3
	1.000	4	3
	Total	1	1
	100.000	5	4
Inflow di KPw Jember	50.000	3	5
	20.000	4	4
	10.000	5	2
	5.000	2	4
	2.000	2	1
	1.000	1	5
	Total	1	5





Hasil peramalan menggunakan metode ARIMAX, DNN dan Hibrida ARIMAX-DNN ditunjukkan pada Gambar 9 dimana terdapat data *in-sample* dan *out-sample*. Periode data *in-sample* adalah bulan Januari 2010 hingga Desember 2017, sedangkan data *out-sample* memiliki periode Januari 2018 hingga Juni 2019. Pada plot *in-sample* maupun *out-sample* menunjukkan bahwa ketiga metode mampu menangkap pola data aktual. Terdapat 3 lonjakan nilai *inflow* pada data *out-sample* yaitu pada Januari 2018, Juni 2018, Januari 2019 dan Juni 2019. Metode ARIMAX dan Hibrida mampu mencapai data aktual saat terjadi lonjakan, kecuali pada Juni 2018 hasil ramalan lebih rendah dibanding data aktual. Namun hasil ramalan metode DNN cenderung lebih tepat mengikuti pola data aktual *out-sample* dibanding metode lainnya

**Tabel 7.** Nilai Keباikan Model Semua Metode

Model	In-Sample		Out-Sample	
	RMSE	sMAPE	RMSE	sMAPE
ARIMAX	40,357	0,135	100,723	0,146
DNN	19,250	0,052	<b>81,327</b>	<b>0,121</b>
Hibrida ARIMAX-DNN	39,658	0,135	100,615	0,144

Tabel 7 menyajikan nilai RMSE dan sMAPE untuk setiap metode. Setelah dilakukan perbandingan, metode DNN memiliki nilai RMSE dan sMAPE terkecil dibandingkan ketiga model lainnya. Sehingga dapat disimpulkan jika *inflow* pecahan Rp50.000 baik dimodelkan menggunakan metode DNN.

Dilakukan pemilihan metode terbaik yaitu berdasarkan nilai RMSE dan sMAPE yang terkecil pada data *out-sample* untuk pecahan lainnya. Berikut adalah metode terbaik yang terpilih untuk semua pecahan di semua KPw.

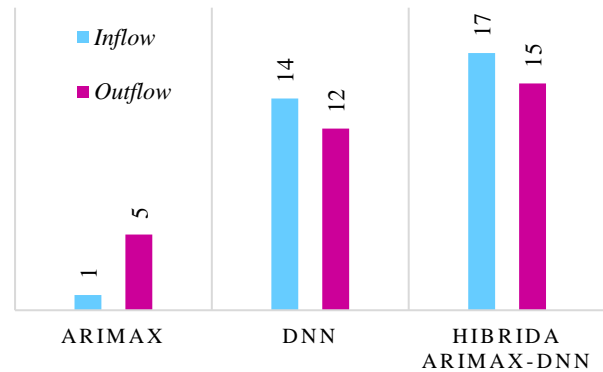
**Tabel 8.** Metode Terbaik untuk Setiap Pecahan

Variabel	Metode Terbaik	
	Inflow	Outflow
Total	Hibrida	Hibrida
100.000	Hibrida	ARIMAX
50.000	DNN	Hibrida
KPw Jember	20.000	Hibrida
10.000	DNN	DNN
5.000	DNN	Hibrida
2.000	DNN	ARIMAX
1.000	DNN	DNN
Total	Hibrida	Hibrida
100.000	Hibrida	Hibrida
50.000	Hibrida	DNN
KPw Kediri	20.000	Hibrida
10.000	Hibrida	DNN
5.000	Hibrida	DNN
2.000	Hibrida	DNN
1.000	DNN	ARIMAX
Total	Hibrida	Hibrida
100.000	DNN	Hibrida
50.000	ARIMAX	Hibrida
KPw Malang	20.000	Hibrida
10.000	Hibrida	Hibrida
5.000	DNN	DNN
2.000	Hibrida	DNN
1.000	DNN	Hibrida

**Tabel 8.** Metode Terbaik untuk Setiap Pecahan (Lanjutan)

Variabel	Metode Terbaik	
	Inflow	Outflow
Total	Hibrida	Hibrida
100.000	DNN	Hibrida
50.000	Hibrida	Hibrida
KPw Surabaya	20.000	DNN
10.000	Hibrida	ARIMAX
5.000	DNN	Hibrida
2.000	DNN	Hibrida
1.000	DNN	ARIMAX

Setelah dilakukan pemilihan metode terbaik *inflow* dan *outflow* di setiap KPw, jumlah metode terbaik untuk semua KPw ditunjukkan pada Gambar 10.

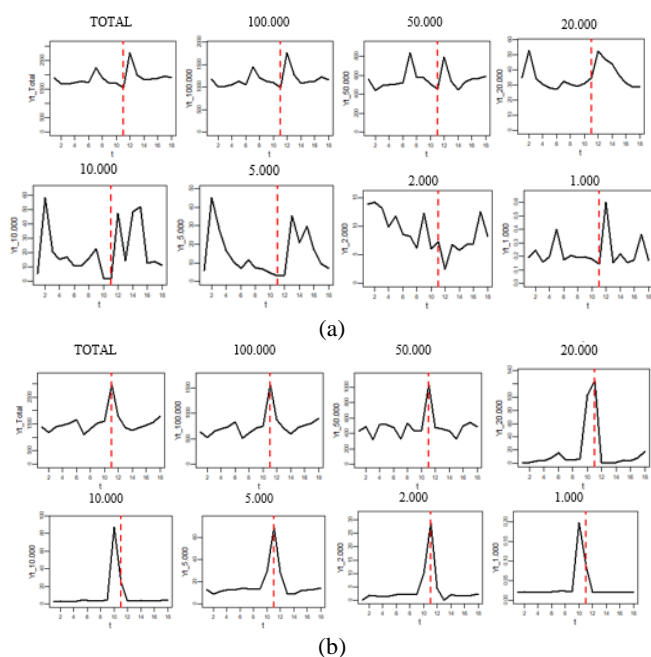


**Gambar 10.** Jumlah Metode Terbaik di Jawa Timur

Gambar 10 menyajikan metode Hibrida ARIMAX-DNN merupakan metode terbaik yang terbanyak untuk meramalkan *inflow* dan *outflow* di semua KPw yang ada di Provinsi Jawa Timur yaitu sebanyak 32 pecahan. Selanjutnya adalah metode DNN pada data *inflow* sebanyak 14 pecahan dan pada data *outflow* sebanyak 12 pecahan. Metode ARIMAX hanya baik digunakan untuk meramalkan 6 pecahan uang kertas. Sehingga dapat disimpulkan bahwa model hibrida dan non-linier cenderung lebih baik untuk memodelkan *inflow* maupun *outflow* pecahan uang kertas yang ada di Jawa Timur. Hal ini menunjukkan jika data *time series* cenderung tidak cukup hanya dimodelkan oleh satu model [15]. Hasil penelitian ini sesuai dengan penelitian *M4-Competition* yang menunjukkan bahwa metode hibrida secara rata-rata mampu meningkatkan akurasi peramalan dibanding model individual [4].

#### F. Peramalan Inflow dan Outflow di Jawa Timur

Langkah selanjutnya adalah melakukan peramalan *inflow* dan *outflow* di Provinsi Jawa Timur berdasarkan model terbaik yang telah dipilih untuk masing-masing pecahan pada setiap KPw. Peramalan yang dilakukan yaitu sebanyak 18 periode kedepan yakni periode bulan Juli 2019 hingga Desember 2020. Peramalan ini dapat digunakan jika kondisi tahun 2020 diasumsikan sama dengan keadaan tahun-tahun sebelumnya. Dengan adanya pandemi COVID-19, hasil peramalan dapat digunakan beberapa persen dari jumlah *inflow* dan *outflow* untuk menyesuaikan kondisi yang ada. Berikut adalah hasil peramalan *inflow* dan *outflow* di KPw Jember.



Gambar 11. Ramalan (a) *Inflow* dan (b) *Outflow* di KPw Jember

Gambar 11 (a) menyajikan hasil ramalan untuk *inflow* dan Gambar 11 (b) menyajikan hasil ramalan *outflow* di KPw Jember untuk 18 periode kedepan yaitu bulan Juli 2019 hingga bulan Desember 2020. Garis merah pada plot merupakan bulan terjadinya Idul Fitri yaitu pada Mei 2020. Pada tahun 2020, Idul Fitri terjadi pada minggu ke-4 sehingga *inflow* akan tinggi pada satu bulan setelah terjadinya Idul Fitri dan *outflow* akan tinggi pada saat terjadinya Idul Fitri.

Sedangkan untuk KPw Kediri, KPw Malang dan KPw Surabaya memiliki pola yang sama untuk hasil ramalan 18 periode kedepan yaitu *inflow* akan tinggi pada satu bulan setelah Idul Fitri yaitu bulan Juni 2020 dan *outflow* akan tinggi pada saat Idul Fitri bulan Mei 2020.

## V. KESIMPULAN DAN SARAN

Berdasarkan hasil analisis dan pembahasan didapatkan bahwa karakteristik total *inflow* dan *outflow* di KPw Surabaya memiliki nilai yang tinggi untuk semua pecahan dibandingkan KPw lainnya, semakin besar nilai pecahan maka rata-rata dan standar deviasi akan semakin besar. Nilai *inflow* mengalami kenaikan pada waktu-waktu tertentu, yakni pada saat Idul Fitri dan satu bulan setelah Idul Fitri. Sedangkan nilai *outflow* mengalami kenaikan pada saat Idul Fitri dan satu bulan sebelum Idul Fitri. Hari raya Idul Fitri yang terjadi pada minggu berbeda akan mengakibatkan perbedaan peningkatan *inflow* dan *outflow* di semua KPw yang ada di Provinsi Jawa Timur. Berdasarkan perbandingan hasil ramalan menggunakan metode ARIMAX, DNN dan Hibrida ARIMAX-DNN menunjukkan bahwa Hibrida ARIMAX-DNN merupakan metode terbaik dalam meramalkan 32 pecahan, selanjutnya metode DNN merupakan metode terbaik dalam meramalkan 26 pecahan dan 6 pecahan lainnya baik diramalkan dengan metode ARIMAX. Hal ini menunjukkan bahwa model hibrida dan non-linier cenderung lebih baik untuk memodelkan *inflow* maupun *outflow* pecahan uang kertas yang ada di Jawa Timur. Dengan asumsi masa mendatang memiliki kondisi yang sama dengan tahun-tahun sebelumnya, hasil peramalan untuk periode Juli 2019 hingga Desember 2020 menunjukkan bahwa *inflow* tertinggi pada

satu bulan setelah Idul Fitri. Sedangkan hasil peramalan *outflow* tertinggi pada saat Idul Fitri. Tingginya *inflow* pada satu bulan setelah Idul Fitri dan tingginya *outflow* pada saat Idul Fitri telah sesuai dengan pola variasi kalender yakni hari raya Idul Fitri yang terjadi pada minggu ke 4 bulan Mei 2020

Saran untuk penelitian selanjutnya adalah sebaiknya mempertimbangkan penggunaan deteksi *outlier* untuk mengatasi asumsi distribusi normal yang tidak terpenuhi. Untuk metode DNN sebaiknya mengoptimalkan *preprocessing* data sehingga menghasilkan peramalan yang lebih baik.

## DAFTAR PUSTAKA

- [1] Bank Indonesia. (2018). *Kajian Ekonomi dan Keuangan Regional Provinsi Jawa Timur*. Surabaya: Kantor Perwakilan Bank Indonesia Provinsi Jawa Timur.
- [2] Suhartono, Lee, M. H., & Hamzah, N. A. (2010). Calendar Variation Model Based on ARIMAX for Forecasting Sales Data with Ramadhan Effect. *Proceedings of the Regional Conference on Statistical Sciences 2010*, (hal. 349-361).
- [3] Schmidhuber, J. (2015). Deep Learning in Neural Network: An overview. *Neural Neural*, 61, 85-117..
- [4] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 Competition: Results, findings, conclusion and way. *International Journal of Forecasting* 34, 802-808.
- [5] Zhang, G. P. (2003). Time Series Forecasting using a Hybrid ARIMA and Neural Network Model. *Neurocomputing* 50, 159-175.
- [6] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018a). Statistical and Machine Learning Forecasting Methods: Concerns and Ways Forward. *PLoS ONE* 13.
- [7] Shumway, R. H., & Stoffer, D. S. (2006). *Time Series Analysis and Its Applications with R Examples*. Pittsburg: Springer.
- [8] Suhartono, Lee, M. H., & Prastyo, D. D. (2015). Two Levels ARIMAX and Regression Models for Forecasting Time Series Data with Calendar Variation Effects. *AIP Conference Proceedings*, (hal. 150-164).
- [9] Crone, S. F., & Kourentzes, N. (2009). Input-variable specification for neural network - An analysis of forecasting low and high time series frequency. *International Joint Conference on Neural Network*.
- [10] Zhang, G. P., & Qi, M. (2005). Neural Network Forecasting for Seasonal and Trend Time Series. *European Journal of Operational Research* 160, 501-514.
- [11] Faraway, J., & Chatfield, C. (1998). Time series forecasting with neural networks: *Appl. Statist.* 47(2), 231-250.
- [12] Suhartono, Ashari, D. E., Prastyo, D. D., Kuswanto, H., & Lee, M. H. (2019). Deep Neural Network for Forecasting Inflow and Outflow in Indonesia. *Sains Malaysiana* 48(8), 1787-1798
- [13] Zhang, G., Pawuto, B. E., & Hu, M. Y. (1998). Forecasting with artificial neural networks: The state of art. *International Journal of Forecasting* 14, 35-62.
- [14] Karlik, B., & Olgac, A. V. (2011). Performance Analysis of Various Activation Functions in Generalized MLP Architectures of Neural Networks. *International Journal of Artificial Intelligence And Expert Systems (IJAE), Volume (1): Issue (4)*, 111-122.
- [15] Khashei, M., & Bijari, M. (2010). An artificial neural network (p, d, q) model for timeseries forecasting. *Expert Systems with Applications* 37, 479-489.
- [16] Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting* 22, 679-688.
- [17] Makridakis, S. (1993). Accuracy measures: theoretical and practical concerns. *International Journal of Forecasting* 9, 527-529.
- [18] Makridakis, S., & Hibon, M. (2000). The M3-Competition: results, conclusions and implications. *International Journal of Forecasting* 16, 451-476.
- [19] Solikin, & Suseno. (2002). *Uang: Pengertian, Penciptaan, dan Peranannya dalam Perekonomian*. Jakarta: Pusat Pendidikan Studi Kebanksentralan (PPSK) Bank Indonesia.
- [20] Bank Indonesia. (2016). *Metadata Uang Kartal yang Diedarkan*. Retrieved January 13, 2020, from <https://www.bi.go.id/id/statistik/-metadata/items/Documents/Tabel-1-Uang-Primer-21102016.pdf>